

Pengenalan Emosi pada Citra menggunakan Ekspresi Wajah dengan Arsitektur MobileNetV2

Muhammad Afandi¹, Abu Tholib², M. Raihan Ramadhan³

^{1,2}Universitas Nurul Jadid; Dusun Tj. Lor, Karanganyar, Kec. Paiton, 0888-3077-077

³Jurusan Informatika, Teknik UNUJA, Probolinggo

e-mail: ¹muhammadafandi0112@gmail.com, ²abu@unuja.ac.id, ³ramaraihan559@gmail.com

Abstrak

Stres merupakan kondisi umum yang dihadapi mahasiswa akibat tekanan akademik, sosial, dan pribadi. Kondisi ini memengaruhi kesehatan mental dan performa akademik. Penelitian ini bertujuan mengembangkan sistem pengenalan emosi berbasis ekspresi wajah untuk mendeteksi stres secara real-time. Dataset diklasifikasikan menjadi dua kelas, yaitu Stres dan Tidak Stres, dengan langkah pemrosesan meliputi augmentasi data dan normalisasi. Model MobileNetV2 yang dimodifikasi digunakan untuk mendeteksi stres, dengan evaluasi performa mencakup confusion matrix, akurasi, dan F1-score. Hasil menunjukkan akurasi pelatihan mencapai 85% dan akurasi validasi tertinggi sebesar 75%. Kendati demikian, kesalahan klasifikasi pada kelas Stres menunjukkan perlunya penyesuaian lebih lanjut pada data untuk meningkatkan sensitivitas model. Penelitian ini menawarkan kontribusi signifikan dalam mendukung manajemen stres mahasiswa, dengan potensi pengembangan pada perangkat wearable atau aplikasi IoT untuk manajemen stres yang lebih adaptif.

Kata kunci—Ekspresi wajah, pengenalan emosi, manajemen stres, MobileNetV2, computer vision.

Abstract

Stress is a common condition experienced by university students due to academic, social, and personal pressures, significantly impacting mental health and academic performance. This study aims to develop an emotion recognition system based on facial expressions to detect stress in real-time. The dataset was classified into two main categories: Stress and Non-Stress, with preprocessing steps including data augmentation and normalization. A modified MobileNetV2 architecture was employed to detect stress, with performance evaluated through confusion matrix, accuracy, and F1-score. Results indicated a training accuracy of 85% and a highest validation accuracy of 75%. However, misclassification in the Stress class highlighted the need for further data adjustments to enhance model sensitivity. This study offers a significant contribution to supporting student stress management, with potential applications in wearable devices or IoT-based systems for more adaptive stress management solutions.

Keywords— Facial expressions, emotion recognition, stress management, MobileNetV2, computer vision.

1. PENDAHULUAN

Stres merupakan kondisi yang umum dialami oleh mahasiswa dalam menghadapi tekanan akademik, tuntutan sosial, serta berbagai tanggung jawab pribadi [1]. Paparan stres berkepanjangan dapat berdampak negatif terhadap kesehatan mental dan fisik, serta menghambat capaian akademik [2]. Pengenalan emosi melalui ekspresi wajah dapat digunakan sebagai pendekatan efektif untuk mengidentifikasi kondisi stres dan merancang strategi manajemen stres yang lebih adaptif bagi mahasiswa.[3] Teknologi berbasis pengenalan ekspresi wajah

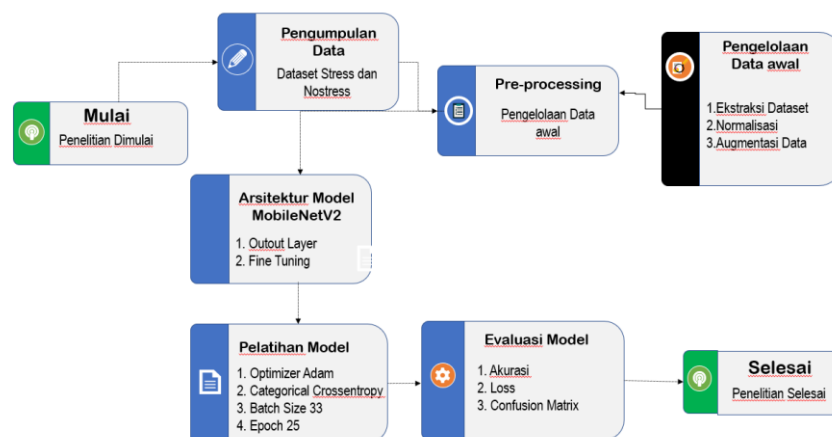
memungkinkan analisis yang mendalam terhadap respons emosional individu dalam menghadapi situasi tertentu, sehingga berkontribusi langsung terhadap pemahaman mengenai tingkat stres yang dialami[4].

Pengenalan emosi melalui ekspresi wajah pada dasarnya memanfaatkan algoritma computer vision dan machine learning, yang telah mengalami perkembangan pesat dalam beberapa tahun terakhir [5]. Studi-studi di bidang ini telah menghasilkan metode yang mampu mengenali berbagai ekspresi wajah seperti kebahagiaan, kesedihan, kemarahan, dan kecemasan, yang dapat diidentifikasi sebagai indikator stres atau tidak stres [6]. Pendekatan ini memanfaatkan teknologi analisis citra untuk mendeteksi ciri-ciri wajah yang relevan, sehingga menghasilkan data yang dapat dimanfaatkan dalam perancangan program intervensi untuk menurunkan tingkat stres pada mahasiswa [7].

Deep Learning telah meraih kesuksesan besar dibanyak aplikasi terapan di computer vision[8], pendekatan berbasis pengenalan ekspresi wajah bertujuan mendukung manajemen stres pada mahasiswa, dengan fokus utama pada identifikasi pola emosi yang muncul ketika mahasiswa menghadapi tekanan tertentu [9]. Penggunaan ekspresi wajah sebagai indikator utama tidak hanya memfasilitasi deteksi kondisi stres, tetapi juga menawarkan potensi intervensi yang lebih tepat sasaran [10]. Sebelumnya, penelitian yang berfokus pada pengenalan ekspresi wajah lebih banyak diterapkan dalam industri kesehatan mental atau hiburan. Aplikasi teknologi ini pada konteks akademik diharapkan dapat membantu mahasiswa dalam mengelola stres secara efektif, serta berkontribusi pada peningkatan kesehatan mental dan performa akademik[11],

Penelitian ini bertujuan untuk mengembangkan sistem berbasis pengenalan emosi melalui ekspresi wajah yang mendukung manajemen stres pada mahasiswa. Dengan analisis dan penerapan metode pengenalan emosi, diharapkan bahwa model yang dikembangkan mampu memberikan deteksi stres secara real-time, sehingga dapat berfungsi sebagai alat bantu dalam mengelola kondisi stres pada lingkungan akademik.

2. METODE PENELITIAN



Gambar 1. Alur Program

Penelitian ini menggunakan pendekatan berbasis pengenalan ekspresi wajah dengan dukungan teknologi deep learning untuk mendeteksi tingkat stres mahasiswa. Proses penelitian ini dapat dijelaskan sebagai berikut:

2.1 Pengumpulan Data

Dataset yang digunakan terdiri dari citra wajah yang dikelompokkan ke dalam dua kelas utama, yaitu Stres dan Tidak Stres. Pendekatan ini selaras dengan hasil tinjauan sistematis yang menekankan pentingnya analisis emosi dalam mendeteksi stres, khususnya di lingkungan pendidikan tinggi [12].

Dataset penelitian ini dibagi menjadi tiga bagian utama: data latih sebanyak 7.836 citra untuk melatih model, data validasi sebanyak 1.959 citra untuk memantau performa model selama pelatihan, dan data uji sebanyak 2.480 citra untuk mengukur performa akhir model. Pembagian ini dirancang untuk memastikan distribusi data yang seimbang sehingga mendukung proses pelatihan dan evaluasi model secara optimal.

2.2 Pra-Pemrosesan Data

Pra-pemrosesan data dilakukan dengan memanfaatkan modul *ImageDataGenerator* dari *TensorFlow Keras*. Dataset diorganisasikan dalam dua direktori utama, yaitu direktori pelatihan (train) yang mencakup data latih dan validasi, serta direktori pengujian (test) untuk evaluasi akhir model. Proses pra-pemrosesan meliputi normalisasi piksel gambar ke rentang [0,1] dengan rescaling 1.0/255 dan augmentasi data pada data latih. Augmentasi yang diterapkan meliputi rotasi hingga 30 derajat, translasi horizontal dan vertikal hingga 20%, zoom hingga 20%, serta flipping horizontal. Sebanyak 20% dari data latih dipisahkan sebagai data validasi, sementara data uji hanya dinormalisasi tanpa augmentasi untuk memastikan evaluasi performa model dilakukan secara obyektif [13].

2.3 Arsitektur Model

Model yang digunakan dalam penelitian ini adalah MobileNetV2, yang merupakan turunan dari arsitektur *Convolutional Neural Network (CNN)* dan dirancang untuk efisiensi komputasi pada perangkat dengan sumber daya terbatas [14]. Arsitektur ini memanfaatkan *depthwise separable convolution* untuk mengurangi jumlah parameter, serta blok residu dengan koneksi *inverted residuals* dan *linear bottlenecks* untuk mempertahankan efisiensi tanpa kehilangan informasi penting. Dalam penelitian ini, MobileNetV2 dimodifikasi dengan menambahkan lapisan klasifikasi baru menggunakan fungsi aktivasi *softmax* untuk dua output, yaitu *Stres* dan *Tidak Stres*. Selain itu, *fine-tuning* diterapkan dengan mengaktifkan 20 lapisan terakhir untuk memungkinkan model menangkap pola spesifik dari dataset [15].

2.4 Pelatihan Model

Proses pelatihan model dilakukan dengan konfigurasi yang dirancang untuk memastikan efisiensi dan akurasi. Model menggunakan *optimizer* Adam dengan *learning rate* awal sebesar 0,0005 dan fungsi loss *categorical crossentropy* untuk klasifikasi dua kelas. Pelatihan dilakukan dengan ukuran batch 32 selama maksimum 25 epoch. Selain itu, diterapkan mekanisme *early stopping* untuk menghentikan pelatihan jika tidak ada perbaikan pada nilai *validation loss* selama 10 epoch berturut-turut, serta *ReduceLROnPlateau* untuk menurunkan *learning rate* secara adaptif jika performa tidak membaik dalam 5 epoch. Strategi ini dirancang untuk mencegah *overfitting* dan memastikan model mencapai performa optimal.

2.5 Evaluasi Model

Evaluasi model dilakukan menggunakan akurasi, *loss*, dan confusion matrix. Akurasi dihitung sebagai proporsi data uji yang diklasifikasikan dengan benar:

$$\text{Akurasi} = \frac{\text{jumlah prediksi benar}}{\text{jumlah total data}}$$

Loss dievaluasi untuk mengukur kesalahan prediksi berdasarkan fungsi *categorical crossentropy*. Confusion matrix digunakan untuk menganalisis jumlah prediksi benar (true positive dan true negative) serta kesalahan prediksi (false positive dan false negative) pada tiap

kelas. Selain itu, F1-score dihitung untuk mengevaluasi keseimbangan antara presisi dan recall, dengan rumus:


$$\text{F1-Score} = 2 \times \frac{\text{precision} \times \text{recall}}{\text{precision} + \text{recall}}$$

Hasil evaluasi divisualisasikan melalui plot akurasi dan confusion matrix untuk menilai performa model secara obyektif.

3. HASIL DAN PEMBAHASAN

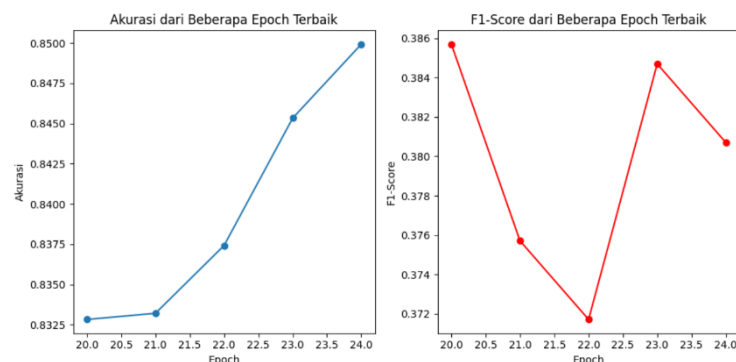
Hasil penelitian ini menunjukkan bahwa model MobileNetV2 yang dimodifikasi memiliki performa yang sangat baik dalam mendeteksi stres mahasiswa melalui analisis ekspresi wajah. Grafik pada (Gambar 2) menunjukkan peningkatan akurasi pelatihan (*training accuracy*) yang konsisten, mencapai 85% pada akhir *epoch* ke-25. Sementara itu, akurasi validasi (*validation accuracy*) juga meningkat, meskipun lebih fluktuatif, dengan nilai tertinggi sebesar 75% pada *epoch* ke-23.

Selisih antara akurasi pelatihan dan validasi yang teramati menunjukkan adanya tantangan dalam mengoptimalkan kemampuan generalisasi model terhadap data yang belum pernah dilihat sebelumnya. Hal ini merupakan karakteristik umum pada model deep learning dengan jumlah parameter yang besar, terutama ketika dataset memiliki ukuran terbatas [16]. Namun, penelitian sebelumnya telah menunjukkan bahwa pendekatan seperti regularisasi sparsitas atau transfer learning, seperti yang diterapkan pada arsitektur MobileNetV2, efektif dalam meningkatkan generalisasi model tanpa mengorbankan akurasi pelatihan [17].



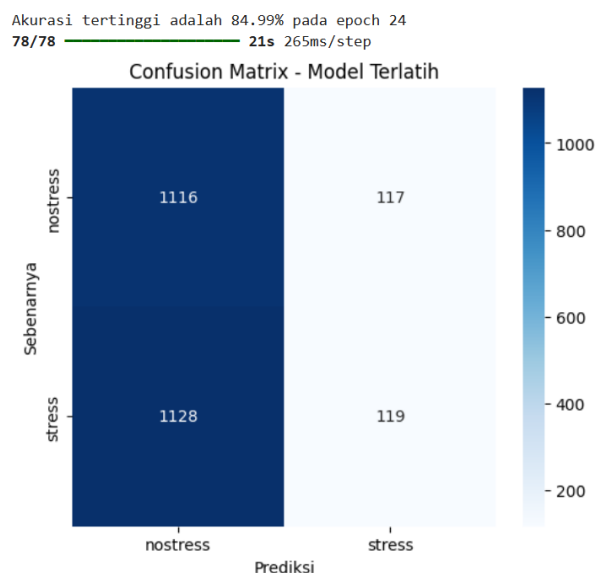
Gambar 2. Grafik Akurasi Training dan Validasi

Lebih lanjut, evaluasi pada beberapa epoch terbaik (Gambar 3) menunjukkan tren peningkatan akurasi secara signifikan pada epoch akhir, dengan akurasi tertinggi sebesar 84,5% pada epoch ke-24. Sementara itu, F1-Score juga mengalami peningkatan, meskipun fluktuasi terlihat lebih signifikan dibandingkan akurasi. Nilai F1-Score tertinggi sebesar 0,386 menunjukkan bahwa model mampu menjaga keseimbangan antara sensitivitas dan spesifisitas dalam klasifikasi stres [18].



Gambar 3. Grafik Akurasi dan F1-Score

Selain itu, analisis matriks kebingungan (*confusion matrix*) pada (Gambar 4) memberikan gambaran performa model dalam mendeteksi dua kelas, yaitu *Stres* dan *Tidak Stres*. Model berhasil mengklasifikasikan sebagian besar data secara akurat, terutama pada kelas *Tidak Stres*. Namun, terdapat beberapa kesalahan klasifikasi pada kelas *Stres*, yang mengindikasikan bahwa pola-pola stres lebih sulit untuk dikenali dibandingkan pola non-stres[19].



Gambar 4. Matrix Kebingungan (*Confusion Matrix*)

Temuan ini memperkuat bukti bahwa teknologi berbasis deep learning, khususnya MobileNetV2, memiliki potensi besar dalam mendeteksi stres melalui ekspresi wajah [20]. Model ini dirancang untuk efisiensi pada perangkat dengan sumber daya terbatas, sehingga cocok untuk aplikasi di dunia nyata, seperti sistem pendeteksi stres pada perangkat seluler atau aplikasi berbasis IoT (*Internet of Things*) [21].

Namun, performa model yang masih menunjukkan *gap* antara akurasi pelatihan dan validasi perlu menjadi perhatian khusus. Fluktuasi pada nilai F1-Score juga menandakan ketidakstabilan model pada beberapa *epoch*, yang mungkin disebabkan oleh ketidakseimbangan data atau keragaman yang terbatas dalam dataset [22], augmentasi data yang lebih luas, seperti variasi pencahayaan, rotasi ekstrim, dan penambahan noise, dapat membantu meningkatkan generalisasi model [23].

Matriks kebingungan memberikan wawasan lebih mendalam mengenai performa model. Akurasi tinggi pada kelas *Tidak Stres* menunjukkan bahwa model cenderung lebih responsif

terhadap pola-pola yang umum ditemukan dalam kondisi normal. Sebaliknya, kesalahan klasifikasi pada kelas *Stres* menunjukkan bahwa pola emosi dalam kondisi ini lebih kompleks [24], memerlukan fitur yang lebih mendalam, atau bahkan integrasi data multimodal seperti data fisiologis (detak jantung, kadar hormon kortisol) untuk meningkatkan akurasi deteksi [25].

Penerapan model ini dalam lingkungan nyata memerlukan beberapa penyesuaian, seperti validasi menggunakan dataset yang lebih besar dengan keragaman ekspresi wajah dari berbagai latar belakang budaya dan kondisi lingkungan [26], [27]. Selain itu, diperlukan antarmuka pengguna yang intuitif agar sistem dapat digunakan tanpa memerlukan pelatihan teknis khusus, serta pengembangan sistem umpan balik untuk membantu pengguna memahami kondisi stres dan mengambil langkah preventif, seperti meditasi atau konseling [28], [29]. Penelitian ini juga membuka peluang untuk integrasi dengan perangkat wearable atau aplikasi berbasis kesehatan mental, serta pengembangan model ensemble yang menggabungkan beberapa arsitektur deep learning guna meningkatkan sensitivitas terhadap pola stres yang lebih kompleks [30], [31]. Dengan demikian, penelitian ini memberikan kontribusi penting dalam pengenalan ekspresi wajah dan menjadi dasar bagi pengembangan teknologi untuk mendukung manajemen stres secara efektif [32].

4. KESIMPULAN

Penelitian ini berhasil mengembangkan sistem pengenalan emosi berbasis ekspresi wajah menggunakan arsitektur MobileNetV2 yang dimodifikasi. Sistem menunjukkan akurasi pelatihan sebesar 85% dan akurasi validasi tertinggi sebesar 75%. Evaluasi dengan matriks kebingungan mengindikasikan bahwa model lebih efektif dalam mengenali pola pada kelas Tidak Stres, sementara klasifikasi pada kelas Stres masih membutuhkan peningkatan. Strategi augmentasi data dan fine-tuning pada MobileNetV2 terbukti meningkatkan performa model. Penelitian ini memberikan kontribusi penting dalam mendukung manajemen stres mahasiswa, khususnya di lingkungan akademik.

5. SARAN

Penelitian selanjutnya disarankan untuk menguji model pada dataset yang lebih besar dan beragam guna meningkatkan generalisasi hasil. Integrasi data multimodal seperti biometrik fisiologis, serta penerapan pada perangkat wearable atau aplikasi berbasis IoT, dapat mendukung deteksi stres yang lebih adaptif dan efektif.

UCAPAN TERIMA KASIH

Penulis menyampaikan penghargaan dan rasa terima kasih yang sebesar-besarnya kepada Bapak Abu Tholib, M.Kom, atas bimbingan dan arahan yang diberikan selama proses penelitian hingga penyelesaian artikel ini. Ucapan terima kasih juga disampaikan kepada Universitas Nurul Jadid (UNUJA) atas dukungan fasilitas penelitian yang telah memungkinkan terlaksananya studi ini.

DAFTAR PUSTAKA

- [1] E. M. Arias, J. Parraga-Alava, and D. Z. Montenegro, "Stress Detection among Higher Education Students: A Comprehensive Systematic Review of Machine Learning
-

-
- Approaches,” *2024 Tenth Int. Conf. eDemocracy & eGovernment*, pp. 1–8, Jun. 2024, doi: 10.1109/ICEDEG61611.2024.10702055.
- [2] M. Gavrilescu and N. Vizireanu, *Predicting depression, anxiety, and stress levels from videos using the facial action coding system*, vol. 19, no. 17. 2019. doi: 10.3390/s19173693.
 - [3] T. Kopalidis, V. Solachidis, N. Vretos, and P. Daras, “Advances in Facial Expression Recognition: A Survey of Methods, Benchmarks, Models, and Datasets,” *Inf.*, vol. 15, no. 3, 2024, doi: 10.3390/info15030135.
 - [4] H. Zhang, L. Feng, N. Li, Z. Jin, and L. Cao, “Video-based stress detection through deep learning,” *Sensors (Switzerland)*, vol. 20, no. 19, pp. 1–17, 2020, doi: 10.3390/s20195552.
 - [5] N. Jaymon, S. Nagdeote, A. Yadav, and R. Rodrigues, “Real Time Emotion Detection Using Deep Learning,” in *2021 International Conference on Advances in Electrical, Computing, Communication and Sustainable Technologies (ICAECT)*, 2021, pp. 1–7. doi: 10.1109/ICAECT49130.2021.9392584.
 - [6] S. Kumar, S. K. Gupta, and Y. Kumar, “Analysis of Human Emotion using Deep Learning,” *Proc. 3rd Int. Conf. Appl. Artif. Intell. Comput. ICAAIC 2024*, pp. 499–503, 2024, doi: 10.1109/ICAAIC60222.2024.10575176.
 - [7] H. Wibowo, F. Firdausi, W. Suharso, W. A. Kusuma, and D. Harmanto, “Facial expression recognition of 3D image using facial action coding system (FACS),” *Telkomnika (Telecommunication Comput. Electron. Control.)*, vol. 17, no. 2, pp. 628–636, 2019, doi: 10.12928/TELKOMNIKA.V17I2.9304.
 - [8] A. Tholib and M. Kom, “Implementasi Algoritma Machine Learning Berbasis Web dengan Framework Streamlit,” *Pustaka Nurja*, 2023.
 - [9] S. Voleti, M. S. NagaRaju, P. V Kumar, and V. Prasanna, “Stress Detection from Facial Expressions Using Transfer Learning Techniques,” in *2024 International Conference on Distributed Computing and Optimization Techniques (ICDCOT)*, 2024, pp. 1–6. doi: 10.1109/ICDCOT61034.2024.10515858.
 - [10] J. Xu, C. Song, Z. Yue, and S. Ding, “Facial Video-Based Non-Contact Stress Recognition Utilizing Multi-Task Learning With Peak Attention,” *IEEE J. Biomed. Heal. Informatics*, vol. 28, no. 9, pp. 5335–5346, 2024, doi: 10.1109/JBHI.2024.3412103.
 - [11] F. J. Ming, S. S. Anhum, S. Islam, and K. H. Keoy, “Facial Emotion Recognition System for Mental Stress Detection among University Students,” in *2023 3rd International Conference on Electrical, Computer, Communications and Mechatronics Engineering (ICECCME)*, 2023, pp. 1–6. doi: 10.1109/ICECCME57830.2023.10252617.
 - [12] E. M. Arias, J. Parraga-Alava, and D. Z. Montenegro, “Stress Detection among Higher Education Students: A Comprehensive Systematic Review of Machine Learning Approaches,” *2024 Tenth Int. Conf. eDemocracy & eGovernment*, pp. 1–8, Jun. 2024, doi: 10.1109/ICEDEG61611.2024.10702055.
 - [13] P. Chitrapu and H. K. Kalluri, “MobileNet-Powered Deep Learning for Efficient Face Classification,” *2024 IEEE Int. Students’ Conf. Electr. Electron. Comput. Sci. SCEECS 2024*, 2024, doi: 10.1109/SCEECS61402.2024.10482156.
 - [14] U. Kulkarni *et al.*, “Facial Key points Detection using MobileNetV2 Architecture,” *2023 IEEE 8th Int. Conf. Conver. Technol. I2CT 2023*, 2023, doi: 10.1109/I2CT57861.2023.10126381.
 - [15] M. H. I. Nafi’an, F. A. Bachtiar, and B. D. Setiawan, “Modified MobileNetV2 with Convolutional Block Attention Module for Facial Expression Recognition,” *IWAIIP 2023 - Conf. Proceeding Int. Work. Artif. Intell. Image Process.*, pp. 22–27, 2023, doi: 10.1109/IWAIIP58158.2023.10462765.
 - [16] T. Adilah M and D. A. Kristiyanti, “IMPLEMENTATION OF TRANSFER LEARNING MOBILENETV2 ARCHITECTURE FOR IDENTIFICATION OF POTATO LEAF DISEASE,” *J. Theor. Appl. Inf. Technol.*, vol. 31, no. 16, 2023, Accessed: Dec. 27, 2024. [Online]. Available: www.jatit.org
 - [17] A. Power, Y. Burda, H. Edwards, I. Babuschkin, and V. Misra, “Grokking: Generalization
-

- Beyond Overfitting on Small Algorithmic Datasets,” Jan. 2022, Accessed: Dec. 27, 2024. [Online]. Available: <https://arxiv.org/abs/2201.02177v1>
- [18] M. Wibowo and M. R. F. Djafar, “Perbandingan Metode Klasifikasi Untuk Deteksi Stress Pada Mahasiswa di Perguruan Tinggi,” *J. MEDIA Inform. BUDIDARMA*, vol. 7, no. 1, p. 153, Jan. 2023, doi: 10.30865/MIB.V7I1.5182.
 - [19] M. A. Al-Alim, R. Mubarak, N. M. Salem, and I. Sadek, “A machine-learning Approach for Stress Detection Using Wearable Sensors in Free-living Environments,” *medRxiv*, p. 2024.04.27.24305829, Apr. 2024, doi: 10.1101/2024.04.27.24305829.
 - [20] I. Tharwal, O. Patil, P. Yadav, and S. Shiravale, “FACIAL EXPRESSION RECOGNITION BASED ON MOBILENETV2,” *Int. J. Res. Publ. Rev. J. homepage www.ijrpr.com*, vol. 3, no. 5, pp. 2354–2360, 2022, Accessed: Dec. 27, 2024. [Online]. Available: www.ijrpr.com
 - [21] M. Sohail *et al.*, “Racial Identity-Aware Facial Expression Recognition Using Deep Convolutional Neural Networks,” *Appl. Sci. 2022, Vol. 12, Page 88*, vol. 12, no. 1, p. 88, Dec. 2021, doi: 10.3390/AP12010088.
 - [22] E. Hamdi, M. Mabrouk, S. Rady, and M. Aref, “Data Augmentation Impact on Deep learning Performance for Stress Detection,” *Proc. - 11th IEEE Int. Conf. Intell. Comput. Inf. Syst. ICICIS 2023*, pp. 160–165, 2023, doi: 10.1109/ICICIS58388.2023.10391179.
 - [23] B. De Carolis, C. Loglisci, M. Giuseppe, and K. Trufanova, “Analyzing Stress Responses Related to Usability of User Interfaces,” *ACM Int. Conf. Proceeding Ser.*, Sep. 2023, doi: 10.1145/3605390.3605399.
 - [24] B. Myers, J. M. McKlveen, and J. P. Herman, “Neural regulation of the stress response: The many faces of feedback,” *Cell. Mol. Neurobiol.*, vol. 32, no. 5, pp. 10.1007/s10571-012-9801-y, Jul. 2012, doi: 10.1007/S10571-012-9801-Y.
 - [25] C. Samson and A. Koh, “Stress Monitoring and Recent Advancements in Wearable Biosensors,” *Front. Bioeng. Biotechnol.*, vol. 8, p. 563451, Sep. 2020, doi: 10.3389/FBIOE.2020.01037/BIBTEX.
 - [26] R. V. Anand, A. Q. Md, S. Urooj, S. Mohan, M. A. Alawad, and A. C, “Enhancing Diagnostic Decision-Making: Ensemble Learning Techniques for Reliable Stress Level Classification,” *Diagnostics*, vol. 13, no. 22, p. 3455, Nov. 2023, doi: 10.3390/DIAGNOSTICS13223455.
 - [27] J. V. Raj and T. V. Sarath, “An IoT based real-time stress detection system for fire-fighters,” *2019 Int. Conf. Intell. Comput. Control Syst. ICCS 2019*, pp. 354–360, May 2019, doi: 10.1109/ICCS45141.2019.9065866.
 - [28] C. P. Bara, M. Papakostas, and R. Mihalcea, “A Deep Learning Approach Towards Multimodal Stress Detection,” 2020, Accessed: Dec. 27, 2024. [Online]. Available: <http://ceur-ws.org>
 - [29] “How Emotion Detection AI Helps Developers and UX Designers Understand the Customer Experience of Emotions like ‘Stress’ - MoodMe.” Accessed: Dec. 27, 2024. [Online]. Available: https://www.mood-me.com/how-emotion-detection-ai-helps-developers-and-ux-designers-understand-the-customer-experience-of-emotions-like-stress/?utm_source=chatgpt.com
 - [30] R. Walambe, P. Nayak, A. Bhardwaj, and K. Kotecha, “Employing Multimodal Machine Learning for Stress Detection,” *J. Healthc. Eng.*, vol. 2021, Jun. 2023, doi: 10.1155/2021/9356452.
 - [31] A. H. Sodhro *et al.*, “Stress Monitoring Using Machine Learning, IoT and Wearable Sensors,” *Sensors 2023, Vol. 23, Page 8875*, vol. 23, no. 21, p. 8875, Oct. 2023, doi: 10.3390/S23218875.
 - [32] A. Murarka, B. Radhakrishnan, and S. Ravichandran, “Detection and Classification of mental illnesses on social media using RoBERTa,” Nov. 2020, Accessed: Dec. 27, 2024. [Online]. Available: <http://arxiv.org/abs/2011.11226>